

Agente Identificador de Fraudes Bancárias: Detecção de Fraudes em Transações com Cartão de Crédito por Aprendizado de Máquina Supervisionado

Cheuk Ki Yu¹, Gabriela Nellesen de Sousa¹, Milton Almeida Leoncio¹

¹Faculdade de Computação e Informática – Universidade Presbiteriana Mackenzie
São Paulo – SP – Brasil

{10419664, 10441930, 10416764}@mackenzista.com.br

Abstract. Card fraud imposes large losses on consumers and financial institutions, and its detection is hindered by extreme class imbalance. This partial report formalizes fraud detection as a supervised binary classification task on the public ULB Credit Card Fraud dataset (284,807 transactions, 0.172% frauds). We present an exploratory data analysis, a leakage-free preparation pipeline (deduplication, cyclic time encoding, log-scaled amount, stratified and temporal splits, SMOTE inside the training folds) and baseline results for Logistic Regression and Random Forest, evaluated with PR-AUC, recall and MCC instead of accuracy. The best baseline, a class-weighted Random Forest, reached PR-AUC of 0.80 and MCC of 0.84, while accuracy proved uninformative (99.8% for a trivial classifier). The next stage will compare tuned Random Forest, XGBoost and SVM, add explainability and discuss ethical risks such as false positives.

Resumo. Fraudes com cartão geram grandes perdas a consumidores e instituições financeiras, e sua detecção é dificultada pelo extremo desbalanceamento entre classes. Este artigo parcial formaliza a detecção de fraudes como classificação binária supervisionada sobre o dataset público Credit Card Fraud (ULB), com 284.807 transações e 0,172% de fraudes. São apresentadas a análise exploratória, um processo de preparação sem vazamento de dados (remoção de duplicatas, codificação cíclica do tempo, transformação logarítmica do valor, divisões estratificada e temporal e SMOTE apenas no treino) e resultados de referência com Regressão Logística e Random Forest, avaliados por PR-AUC, Recall e MCC em vez de acurácia. O melhor modelo de referência, uma Random Forest com pesos balanceados, obteve PR-AUC de 0,80 e MCC de 0,84, enquanto a acurácia se mostrou pouco informativa (99,8% para um classificador trivial). A próxima etapa comparará Random Forest ajustada, XGBoost e SVM, com explicabilidade e análise de riscos éticos.

1. Introdução

1.1. Contextualização

A digitalização dos meios de pagamento ampliou o volume de transações eletrônicas e, com ele, as oportunidades de fraude. No Brasil, a Federação Brasileira de Bancos (Febraban) estimou em R\$ 10,1 bilhões as perdas com golpes e fraudes em canais eletrônicos e cartões em 2024, alta de 17% em relação a 2023 [Poder360 2025]. Para as instituições financeiras, identificar rapidamente uma transação fraudulenta entre milhões de

transações legítimas é um problema de decisão sob incerteza, no qual regras fixas escritas por especialistas tendem a ficar desatualizadas diante de novas estratégias dos fraudadores [Dal Pozzolo et al. 2018].

O aprendizado de máquina oferece uma alternativa: modelos que aprendem, a partir de transações históricas rotuladas, padrões que distinguem operações legítimas de fraudulentas. O problema, porém, tem uma dificuldade central: as fraudes são raras. No conjunto de dados usado neste trabalho, elas correspondem a cerca de 0,17% das transações [Machine Learning Group – ULB 2018], o que torna métricas usuais, como a acurácia, enganosas e exige técnicas específicas de tratamento do desbalanceamento [Chawla et al. 2002, Saito and Rehmsmeier 2015].

1.2. Justificativa

Um sistema de detecção precisa equilibrar dois tipos de erro com custos distintos. O *falso negativo* (fraude não detectada) gera prejuízo financeiro direto. O *falso positivo* (transação legítima bloqueada) gera atrito com o cliente, custo operacional de análise manual e perda de confiança. Comparar de forma controlada diferentes algoritmos e estratégias de balanceamento, com métricas adequadas a classes raras, fornece evidência quantitativa para escolher modelos que reduzam ambos os erros. O tema se alinha aos Objetivos de Desenvolvimento Sustentável (ODS) 8, por contribuir para um sistema financeiro mais seguro e com menos perdas econômicas; 9, pela aplicação de ciência de dados e inovação tecnológica à infraestrutura financeira; e 16, pelo combate a crimes financeiros.

1.3. Motivação

A motivação do grupo está em aplicar os conteúdos da disciplina a um problema real, de alto impacto e com dificuldades técnicas não triviais (desbalanceamento extremo, atributos anonimizados e custo assimétrico dos erros). O projeto também será aprofundado no Trabalho de Conclusão de Curso dos integrantes, o que reforça a importância de uma base metodológica sólida e reproduzível desde esta etapa.

1.4. Objetivo

Desenvolver e avaliar modelos de aprendizado de máquina supervisionado para classificar transações com cartão de crédito como legítimas ou fraudulentas, comparando algoritmos (Regressão Logística como referência, Random Forest, XGBoost e SVM) e estratégias de tratamento do desbalanceamento (pesos de classe e SMOTE), com ênfase na maximização da detecção de fraudes (Recall) e no controle dos falsos positivos (Precisão).

1.5. Contribuições esperadas

Espera-se contribuir com: (i) a formalização da detecção de fraudes como tarefa de classificação binária supervisionada; (ii) uma análise exploratória documentada do dataset, identificando suas características e limitações; (iii) um protocolo experimental sem vazamento de dados, com validação estratificada e temporal; (iv) a comparação quantitativa entre modelos e estratégias de balanceamento por métricas adequadas a classes raras; (v) a análise dos atributos mais relevantes às decisões dos modelos; (vi) um protótipo capaz de classificar novas transações; e (vii) um repositório público que permita reproduzir todos os experimentos.

1.6. Evolução em relação à proposta

Em relação à proposta inicial, o escopo foi refinado em quatro pontos. Primeiro, o dataset foi definido (Seção 3.3). Segundo, a acurácia deixou de ser métrica de decisão, pois um classificador que rotula todas as transações como legítimas já atinge cerca de 99,8%; as métricas principais passaram a ser PR-AUC, Recall, Precisão, F1 e MCC [Saito and Rehmsmeier 2015, Chicco and Jurman 2020]. Terceiro, foi acrescentada uma validação com divisão temporal, mais próxima do uso real. Por fim, como o dataset cobre apenas dois dias, a adaptação a novas estratégias de fraude ao longo do tempo (*concept drift*) será discutida como limitação, e não avaliada experimentalmente.

2. Fundamentação Teórica

2.1. Agentes, aprendizado supervisionado e classificação

Em Inteligência Artificial, um agente é uma entidade que percebe o ambiente e age sobre ele [Russell and Norvig 2021]. No sistema proposto, o agente percebe cada nova transação, estima sua probabilidade de fraude por meio de um modelo aprendido e age emitindo ou não um alerta para análise. O modelo é obtido por *aprendizado supervisionado*: dado um conjunto de exemplos $\{(\mathbf{x}_i, y_i)\}$, em que $\mathbf{x}_i$ é o vetor de atributos da transação e $y_i \in \{0, 1\}$ indica se ela é fraudulenta, busca-se uma função $f(\mathbf{x})$ que generalize para transações não vistas. A saída é uma probabilidade, convertida em decisão por um limiar τ . A escolha de τ controla diretamente o compromisso entre Precisão e Recall.

2.2. Aprendizado com classes desbalanceadas

Quando uma classe é muito rara, algoritmos que minimizam o erro global tendem a ignorá-la. Há duas famílias de soluções. Nas abordagens em nível de algoritmo, atribui-se peso maior aos erros na classe minoritária (*class weights*). Nas abordagens em nível de dados, a distribuição de treino é reamostrada. O SMOTE (*Synthetic Minority Over-sampling Technique*) cria exemplos sintéticos da classe minoritária por interpolação entre um exemplo e seus vizinhos mais próximos [Chawla et al. 2002]. A reamostragem deve ser aplicada somente nos dados de treino, pois aplicá-la antes da divisão contamina o conjunto de teste e superestima o desempenho. Além disso, ela altera as probabilidades estimadas pelo modelo, o que pode exigir calibração posterior [Dal Pozzolo et al. 2015].

2.3. Modelos de classificação

A **Regressão Logística** modela a probabilidade de fraude como uma função sigmoide de uma combinação linear dos atributos. É simples e interpretável, por isso serve de referência. A **Random Forest** [Breiman 2001] combina muitas árvores de decisão treinadas sobre amostras *bootstrap* e subconjuntos aleatórios de atributos. A votação reduz a variância e captura relações não lineares. O **XGBoost** [Chen and Guestrin 2016] constrói árvores sequencialmente por *gradient boosting*, cada uma corrigindo os resíduos das anteriores, com regularização e parâmetro próprio para desbalanceamento. As **Máquinas de Vetores de Suporte** (SVM) [Cortes and Vapnik 1995] buscam o hiperplano de margem máxima entre as classes, podendo usar *kernels* para fronteiras não lineares. Seu custo de treinamento cresce de forma aproximadamente quadrática com o número de exemplos, o que exige subamostragem ou versão linear em bases grandes.

2.4. Métricas de avaliação

Sejam VP, FP, VN e FN os verdadeiros positivos, falsos positivos, verdadeiros negativos e falsos negativos. A *Precisão* ($\frac{VP}{VP+FP}$) mede a fração de alertas que são fraudes reais. O *Recall* ($\frac{VP}{VP+FN}$) mede a fração de fraudes detectadas, e o *F1* é a média harmônica das duas. A área sob a curva Precisão–Recall (PR-AUC, ou *average precision*) resume o desempenho em todos os limiares e é mais informativa que a área sob a curva ROC quando a classe positiva é rara [Saito and Rehmsmeier 2015]. O coeficiente de correlação de Matthews (MCC) considera as quatro células da matriz de confusão e só é alto quando o classificador acerta bem ambas as classes [Chicco and Jurman 2020].

2.5. Trabalhos relacionados

Em [Bhattacharyya et al. 2011], os autores compararam Regressão Logística, SVM e Random Forest em dados reais de transações de cartão e concluíram que a Random Forest apresentou o melhor desempenho geral, destacando a importância de avaliar os modelos sob diferentes proporções de fraude. Os autores do dataset utilizado neste trabalho [Dal Pozzolo et al. 2015] mostraram que a subamostragem da classe majoritária distorce as probabilidades previstas e propuseram uma correção de calibração. Em trabalho posterior, [Dal Pozzolo et al. 2018] argumentam que avaliações realistas devem considerar a ordem temporal das transações, o atraso na chegada dos rótulos e o número limitado de alertas que analistas conseguem verificar, propondo métricas de precisão sobre os alertas.

No mesmo dataset, [Awoyemi et al. 2017] avaliaram Naïve Bayes, k-vizinhos mais próximos (KNN) e Regressão Logística com amostragem híbrida, e o KNN obteve o melhor desempenho entre os três. Já [Varmedja et al. 2019] aplicaram SMOTE e compararam Regressão Logística, Random Forest, Naïve Bayes e Perceptron Multicamadas, com melhor resultado geral para a Random Forest. Ambos os estudos, porém, aplicaram a reamostragem com pouco detalhe sobre o protocolo e enfatizaram a acurácia, o que dificulta a comparação direta. O estudo de [Carcillo et al. 2021] mostrou que incluir escores de detecção de anomalias não supervisionada como atributos de modelos supervisionados pode melhorar a detecção. Por fim, o manual de [Le Borgne et al. 2022] sistematiza boas práticas reprodutíveis, com ênfase em validação temporal e métricas voltadas a alertas.

Esses trabalhos fundamentam as decisões deste projeto: comparar modelos de *ensemble* (que se destacam na literatura) contra uma referência linear; aplicar SMOTE apenas no treino; priorizar PR-AUC e MCC em vez de acurácia; e incluir uma validação temporal. A Tabela 1 resume a comparação.

3. Metodologia e Resultados Esperados

3.1. Abordagem e etapas

O projeto segue um fluxo típico de ciência de dados, implementado em Python com scikit-learn [Pedregosa et al. 2011] e imbalanced-learn [Lemaître et al. 2017]:

1. **Aquisição e análise exploratória** (N1): estrutura, qualidade, desbalanceamento e separabilidade dos atributos.
2. **Preparação** (N1): remoção de duplicatas, engenharia de atributos, divisão treino/teste e padronização.

Tabela 1. Síntese dos trabalhos relacionados

Trabalho	Técnicas	Solução obtida / relação com este projeto
Bhattacharyya et al. (2011)	RL, SVM, RF	RF com melhor desempenho geral; motiva o uso de <i>ensembles</i> .
Dal Pozzolo et al. (2015)	Subamostragem, calibração	Correção das probabilidades após reamostragem; alerta para efeitos do balanceamento.
Dal Pozzolo et al. (2018)	Aprendizado com <i>feedback</i> e rótulos atrasados	Avaliação realista e temporal; motiva a validação temporal.
Awoyemi et al. (2017)	NB, KNN, RL + amostragem híbrida	KNN superior no mesmo dataset; ênfase em acurácia.
Varmedja et al. (2019)	RL, RF, NB, MLP + SMOTE	RF com melhor resultado geral no mesmo dataset.
Carcillo et al. (2021)	Não supervisionado + supervisionado	Escore de anomalia como atributos melhoram a detecção; possível extensão futura.
Le Borgne et al. (2022)	Diversos	Boas práticas reprodutíveis, validação temporal e métricas voltadas a alertas.

3. **Modelos de referência** (N1): classificador trivial, Regressão Logística (com pesos e com SMOTE) e Random Forest com pesos balanceados.
4. **Modelagem e ajuste** (N2): Random Forest, XGBoost e SVM, com busca de hiperparâmetros por validação cruzada estratificada e comparação entre pesos de classe e SMOTE.
5. **Escolha do limiar e avaliação** (N2): definição de τ em validação, avaliação final no teste e na divisão temporal.
6. **Explicabilidade** (N2): importância por permutação e valores SHAP [Lundberg and Lee 2017].
7. **Protótipo** (N2): aplicação que recebe uma transação e devolve a probabilidade de fraude e a decisão.

Em todas as etapas, as transformações que aprendem parâmetros dos dados (padronização e SMOTE) são encapsuladas em *pipelines* ajustados somente no treino (e em cada dobra da validação cruzada), evitando vazamento de informação para o teste.

3.2. Resultados esperados

Espera-se que os modelos de *ensemble* superem a Regressão Logística em PR-AUC e MCC, em linha com a literatura [Bhattacharyya et al. 2011, Varmedja et al. 2019], e que SMOTE e pesos de classe aumentem o Recall à custa de parte da Precisão. Espera-se também que o desempenho na divisão temporal seja igual ou inferior ao da divisão aleatória, evidenciando o efeito da ordem temporal.

3.3. Dataset

3.3.1. Origem e conteúdo

Foi utilizado o dataset *Credit Card Fraud Detection*, coletado pelo Machine Learning Group da Université Libre de Bruxelles em colaboração com a Worldline e disponibilizado publicamente no Kaggle [Machine Learning Group – ULB 2018, Dal Pozzolo et al. 2015]. Ele contém 284.807 transações realizadas em dois dias de

setembro de 2013 por portadores de cartão europeus, das quais 492 são fraudes (0,172%). Os atributos $V1-V28$ são componentes principais (PCA) de atributos originais não divulgados por confidencialidade. Apenas *Time* (segundos desde a primeira transação) e *Amount* (valor) não foram transformados. A variável-alvo é *Class*.

3.3.2. Qualidade, adequação e limitações

Por serem transações reais rotuladas, os dados são representativos do problema, e a anonimização por PCA elimina dados pessoais. Isso, porém, tem custos: (i) $V1-V28$ não têm significado semântico, o que limita a engenharia de atributos e a explicabilidade das decisões para usuários finais; (ii) como o horário real de início da coleta não é informado, a hora derivada de *Time* é relativa; (iii) dois dias não permitem avaliar sazonalidade nem *concept drift*; (iv) as fraudes são poucas em números absolutos, o que torna as métricas sensíveis a poucos erros e exige cautela na interpretação; e (v) não há atributos demográficos, o que impede auditar vieses contra grupos específicos. Essas limitações são consideradas na interpretação dos resultados.

3.3.3. Análise exploratória

As 284.807 transações abrangem 48 horas. O conjunto não possui valores ausentes, mas contém 1.081 linhas duplicadas, das quais 19 são fraudes. A Figura 1 mostra o desbalanceamento: após a remoção das duplicatas, restam 283.253 transações legítimas e 473 fraudes (0,167%), uma razão de aproximadamente 599:1.




Figura 1. Distribuição das classes (escala logarítmica)

Quanto ao valor (Figura 2), as fraudes têm mediana *menor* que as transações legítimas (9,82 contra 22,00), mas média *maior* (123,87 contra 88,41). Isso indica uma concentração de fraudes em valores muito baixos, possivelmente testes de validade do cartão, ao lado de algumas fraudes de valor elevado. Transações de valor zero são 5,3% das fraudes e apenas 0,6% das legítimas. O maior valor legítimo (25.691,16) supera em muito a maior fraude (2.125,87), e a distribuição é fortemente assimétrica: 11,2% das transações estão acima de $Q_3 + 1,5 \text{ IQR}$. Por isso, optou-se pela transformação logarítmica em vez da remoção de valores extremos, que em fraude podem ser justamente os casos de interesse.

A estatística de Kolmogorov–Smirnov (KS) entre as classes para Amount foi de 0,265, indicando separação apenas moderada. O valor, isoladamente, não identifica fraudes.




Figura 2. Distribuição de $\log(1 + \text{Amount})$ por classe

A Figura 3 mostra o volume de transações e a taxa de fraude por hora relativa. Há um ciclo nítido: entre as horas relativas 1 e 7 o volume cai drasticamente (mínimo na hora 4), padrão compatível com o período noturno. Nesse intervalo, a taxa de fraude sobe e atinge 1,45% na hora 2, cerca de 5,5 vezes a média horária de 0,26%. Como o denominador é pequeno nessas horas, parte da variação pode ser ruído. Ainda assim, o padrão justifica incluir a hora como atributo.




Figura 3. Volume de transações e taxa de fraude por hora relativa ao início da coleta

Entre os componentes PCA, a correlação máxima em módulo entre pares foi de 0,019, confirmando a quase ortogonalidade esperada da PCA. Os atributos mais correlacionados com a classe têm correlação negativa, com destaque para V17 (−0,31), V14 (−0,29) e V12 (−0,25) (Figura 4). Pela estatística KS, os mais separadores são V14 (0,84), V10 (0,80), V12 (0,78) e V4 (0,76) (Figura 5), enquanto 4 componentes apresentaram KS inferior a 0,1. Isso indica que a informação discriminativa está concentrada em poucos componentes.




Figura 4. Atributos mais correlacionados com a classe




Figura 5. Distribuições por classe dos quatro atributos com maior estatística KS

3.3.4. Preparação dos dados

Com base na análise, foram tomadas as seguintes decisões: (i) remoção das duplicatas antes da divisão, evitando que a mesma transação apareça no treino e no teste; (ii) substituição de `Time` pela hora relativa em codificação cíclica ($\sin$ e $\cos$ de $2\pi h/24$), que preserva a proximidade entre 23h e 0h; (iii) transformação $\log(1 + \text{Amount})$; (iv) divisão estratificada 80/20 com semente fixa, resultando em 226.980 transações de treino (378 fraudes) e 56.746 de teste (95 fraudes); (v) padronização com `RobustScaler` (mediana e intervalo interquartil), menos sensível a valores extremos; e (vi) SMOTE aplicado somente ao treino, dentro do *pipeline*. O conjunto final possui 31 atributos.

4. Resultados Parciais

4.1. Aspectos éticos e responsabilidade no uso da IA

Privacidade e proteção de dados. O dataset foi anonimizado pelos autores antes da publicação e não contém dados pessoais identificáveis. O grupo não fará nenhuma tentativa de reidentificação. Em uma aplicação real, dados de transações são dados pessoais sujeitos à LGPD [Brasil 2018]. O uso para prevenção de fraudes precisaria de base legal adequada, minimização dos dados coletados e controles de acesso e retenção.

Custo assimétrico dos erros. Um falso positivo bloqueia a compra legítima de um cliente, o que pode ter consequências sérias (por exemplo, numa compra de medicamento ou numa emergência). Um falso negativo transfere o prejuízo ao cliente ou à insti-

tuição. Por isso, o projeto reporta os dois tipos de erro separadamente, escolhe o limiar de decisão de forma explícita e propõe que o modelo atue como *apoio à decisão*: alertas vão para verificação (por exemplo, confirmação com o cliente), e não para bloqueio definitivo automático.

Transparência e explicabilidade. A LGPD garante ao titular o direito de solicitar a revisão de decisões tomadas unicamente com base em tratamento automatizado (art. 20). Como V1–V28 não têm significado semântico, explicações em termos desses atributos são úteis para auditoria técnica, mas não para o cliente. O projeto usará SHAP [Lundberg and Lee 2017] para auditoria e reconhece essa limitação. Em produção, seriam necessários atributos interpretáveis.

Viés e equidade. A ausência de atributos demográficos protege a privacidade, mas impede verificar se o modelo erra mais para determinados grupos, por exemplo, gerando mais bloqueios para perfis de consumo menos comuns. Esse risco não pode ser descartado. Em um uso real, seria necessária auditoria periódica das taxas de falso positivo por segmento.

Robustez e responsabilidade. Fraudadores adaptam seu comportamento, e um modelo treinado em dois dias de 2013 não deve ser tratado como válido para o cenário atual. Resultados obtidos neste dataset público não devem ser apresentados como garantia de desempenho em produção. Medidas de mitigação seriam o monitoramento contínuo, o retreinamento periódico e a supervisão humana dos alertas.

4.2. Resultados parciais obtidos

A Tabela 2 apresenta os resultados dos modelos de referência no conjunto de teste, com limiar $\tau = 0,5$, e a PR-AUC média na validação cruzada estratificada com 5 dobras no treino.

Tabela 2. Resultados dos modelos de referência no conjunto de teste

Modelo	Acur.	Prec.	Recall	F1	MCC	PR-AUC	PR-AUC (CV)
Dummy (majoritária)	0,998	0,000	0,000	0,000	0,000	0,002	0,002 $\pm$ 0,000
RL (pesos)	0,975	0,056	0,874	0,105	0,217	0,680	0,756 $\pm$ 0,027
RL + SMOTE	0,974	0,053	0,874	0,100	0,212	0,678	0,756 $\pm$ 0,025
RF (pesos)	0,9995	0,972	0,726	0,831	0,840	0,801	0,837 $\pm$ 0,030

O classificador trivial confirma que a acurácia é enganosa neste problema: ele atinge 99,8% sem detectar nenhuma fraude. As métricas focadas na classe positiva revelam diferenças que a acurácia esconde.

As duas variantes de Regressão Logística detectaram 83 das 95 fraudes do teste (Recall de 87,4%), mas geraram cerca de 1.400 falsos positivos (Figura 7), ou seja, aproximadamente 17 alertas falsos para cada fraude detectada (Precisão de 5,6%). A Random Forest apresentou o comportamento oposto: apenas 2 falsos positivos (Precisão de 97,2%), mas 26 fraudes não detectadas (Recall de 72,6%). Nas métricas que resumem o equilíbrio entre os erros, a Random Forest foi claramente superior: MCC de 0,84 contra 0,22 e PR-AUC de 0,80 contra 0,68. O resultado da validação cruzada (0,84 $\pm$ 0,03 contra 0,76 $\pm$ 0,03) confirma que a diferença não se deve à partição de teste escolhida.

Dois achados merecem destaque. Primeiro, o SMOTE não trouxe ganho em relação aos pesos de classe na Regressão Logística: os resultados foram praticamente idênticos, com ligeiro aumento de falsos positivos (1.477 contra 1.406) e maior custo computacional. Na N2, a comparação entre as duas estratégias será repetida nos modelos de árvores. Segundo, a Random Forest teve ROC-AUC *menor* que a Regressão Logística (0,935 contra 0,963), embora tenha PR-AUC muito maior (Figura 6). Isso ilustra empiricamente o argumento de [Saito and Rehmsmeier 2015]: com classes raras, a curva ROC é dominada pela grande massa de verdadeiros negativos e pode ordenar os modelos de forma diferente da curva Precisão–Recall, que reflete melhor o custo operacional dos alertas.

Os perfis opostos de erro mostram também que o limiar padrão $\tau = 0,5$ não é adequado para ambos. A escolha do limiar em validação, conforme o custo relativo de falsos positivos e falsos negativos, é portanto uma etapa necessária da N2.




Figura 6. Curvas Precisão–Recall no conjunto de teste




Figura 7. Matrizes de confusão dos modelos de referência

A importância dos atributos na Random Forest (Figura 8) é coerente com a análise exploratória. Os seis atributos mais importantes (V14, V10, V12, V4, V11 e V17) são exatamente os seis de maior estatística KS, e V14 concentra sozinho 22% da importância total. Os atributos derivados de valor e hora não aparecem entre os dez mais importantes, o que sugere que sua informação é, em grande parte, redundante com os componentes PCA.




Figura 8. Atributos mais importantes na Random Forest

Na divisão temporal (treino nas primeiras 80% das transações e teste nas 20% finais, com 74 fraudes), a Random Forest manteve PR-AUC de 0,80 e Precisão de 98,0%, mas o Recall caiu de 72,6% para 67,6%. A Regressão Logística teve PR-AUC de 0,76, mas dobrou os falsos positivos (2.836) com o limiar padrão. Ao contrário do esperado, não houve degradação expressiva da Random Forest. Como o conjunto cobre apenas dois dias, isso não demonstra robustez a mudanças de padrão de fraude ao longo de meses: indica apenas que não há mudança forte dentro dessa janela.

Uma limitação deve ser considerada ao interpretar todos esses números: com 95 fraudes no teste, cada fraude corresponde a cerca de 1,05 ponto percentual de Recall. Por isso, as comparações devem se apoiar também na validação cruzada. Esses resultados estabelecem o patamar que os modelos da próxima etapa (Random Forest ajustada, XG-Boost e SVM) devem superar, a saber PR-AUC de 0,80 e MCC de 0,84, com atenção especial ao aumento do Recall sem perda significativa de Precisão.

4.3. Repositório

Os artefatos deste trabalho (artigo, descrição do dataset, notebook e resultados) estão disponíveis em: <https://github.com/NewsMoney/IA-projeto-parcial-1>.

Referências

- Awoyemi, J. O., Adetunmbi, A. O., and Oluwadare, S. A. (2017). Credit card fraud detection using machine learning techniques: A comparative analysis. In *International Conference on Computing Networking and Informatics (ICCNi)*, pages 1–9. IEEE.
- Bhattacharyya, S., Jha, S., Tharakunnel, K., and Westland, J. C. (2011). Data mining for credit card fraud: A comparative study. *Decision Support Systems*, 50(3):602–613.
- Brasil (2018). Lei n.º 13.709, de 14 de agosto de 2018: Lei geral de proteção de dados pessoais (LGPD). Disponível em: https://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/l13709.htm.
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1):5–32.

- Carcillo, F., Le Borgne, Y.-A., Caelen, O., Kessaci, Y., Oblé, F., and Bontempi, G. (2021). Combining unsupervised and supervised learning in credit card fraud detection. *Information Sciences*, 557:317–331.
- Chawla, N. V., Bowyer, K. W., Hall, L. O., and Kegelmeyer, W. P. (2002). SMOTE: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, 16:321–357.
- Chen, T. and Guestrin, C. (2016). XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794.
- Chicco, D. and Jurman, G. (2020). The advantages of the Matthews correlation coefficient (MCC) over F1 score and accuracy in binary classification evaluation. *BMC Genomics*, 21:6.
- Cortes, C. and Vapnik, V. (1995). Support-vector networks. *Machine Learning*, 20(3):273–297.
- Dal Pozzolo, A., Boracchi, G., Caelen, O., Alippi, C., and Bontempi, G. (2018). Credit card fraud detection: A realistic modeling and a novel learning strategy. *IEEE Transactions on Neural Networks and Learning Systems*, 29(8):3784–3797.
- Dal Pozzolo, A., Caelen, O., Johnson, R. A., and Bontempi, G. (2015). Calibrating probability with undersampling for unbalanced classification. In *IEEE Symposium Series on Computational Intelligence (SSCI)*, pages 159–166. IEEE.
- Le Borgne, Y.-A., Siblini, W., Lebigot, B., and Bontempi, G. (2022). *Reproducible Machine Learning for Credit Card Fraud Detection – Practical Handbook*. Université Libre de Bruxelles. Disponível em: <https://github.com/Fraud-Detection-Handbook/fraud-detection-handbook>.
- Lemaître, G., Nogueira, F., and Aridas, C. K. (2017). Imbalanced-learn: A Python toolbox to tackle the curse of imbalanced datasets in machine learning. *Journal of Machine Learning Research*, 18(17):1–5.
- Lundberg, S. M. and Lee, S.-I. (2017). A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems 30 (NeurIPS)*, pages 4765–4774.
- Machine Learning Group – ULB (2018). Credit card fraud detection: Anonymized credit card transactions labeled as fraudulent or genuine. Kaggle. Disponível em: <https://www.kaggle.com/datasets/mlg-ulb/creditcardfraud>. Acesso em: 24 set. 2026.
- Pedregosa, F. et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830.
- Poder360 (2025). Golpes causaram prejuízo de R\$ 10,1 bi em 2024, diz Febraban. Disponível em: <https://www.poder360.com.br/poder-economia/golpes-causaram-prejuizo-de-r-101-bi-em-2024-diz-febraban/>. Acesso em: 24 set. 2026.
- Russell, S. and Norvig, P. (2021). *Artificial Intelligence: A Modern Approach*. Pearson, 4th edition.

- Saito, T. and Rehmsmeier, M. (2015). The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. *PLOS ONE*, 10(3):e0118432.
- Varmedja, D., Karanovic, M., Sladojevic, S., Arsenovic, M., and Anderla, A. (2019). Credit card fraud detection – machine learning methods. In *18th International Symposium INFOTEH-JAHORINA*, pages 1–5. IEEE.